

Matriz de Optimización de Costos

Ecosistema de Automatización IA en n8n | Proyecto Final Coderhouse

AUTOR / ALUMNO

Martín Urrutia

DOMINIO DEL FLUJO

Logística Naviera
(Sobrecostos)

ESTRATEGIA TECNOLÓGICA

Inferencia Optimizada vía
Groq

1. Resumen Ejecutivo y Alineación con la Rúbrica

Este documento constituye el entregable de la **Matriz de Optimización de Costos** para el proyecto final. El ecosistema n8n automatiza la ingesta de correos electrónicos sobre costos portuarios (Demurrage, Detention, Storage), gestiona registros relacionales en *Airtable*, ejecuta validaciones estructuradas mediante IA con control de fallos, y escala la toma de decisiones críticas (montos altos o prioridades elevadas) hacia canales interactivos en *Slack*.

Para cumplir rigurosamente con los estándares de la rúbrica (eficiencia presupuestaria, robustez ante fallos y justificación de asignación de modelos), se ha estructurado una arquitectura híbrida optimizada.

2. Cuadro Comparativo de Modelos y Asignación en el Flujo

A continuación se detalla la matriz de decisión estratégica que correlaciona cada componente del flujo n8n con el modelo de IA asignado, contrastando el diseño académico actual con alternativas de mercado:

Rol en el Ecosistema	Modelo Asignado (Flujo Real)	Tarea Específica en el Flujo n8n	Justificación Estratégica
Modelo Principal (Lectura Densa)	openai/gpt-oss-120b vía Groq API	Procesamiento y clasificación densa de correos de sobrecostos (extracción de cifras, naviera, tipo de costo).	Alta capacidad de razonamiento lógico y contexto para interpretar correos complejos con múltiples montos y fechas sin incurrir en costos comerciales directos.
Modelo Fallback (Control de Errores)	openai/gpt-oss-20b vía Groq API	Ruta de respaldo ante caídas de latencia o fallos de esquema en el nodo principal (Structured Output Parser).	Garantiza continuidad operativa (alta disponibilidad) con un modelo más ligero que absorbe picos sin comprometer el SLA del flujo.
Alternativa Comercial (Referencia Rúbrica)	GPT-4o-mini / Claude 3.5 Sonnet	Benchmark conceptual de tareas mecánicas vs. lectura densa analizada en la rúbrica.	Costosos para volúmenes masivos directos; superados en eficiencia económica por la infraestructura acelerada de Groq en fase académica.

3. Estimación de Tokens por Ejecución y Análisis de Costos

El flujo n8n opera con los siguientes parámetros técnicos configurados en los nodos de IA: **Temperature: 0** (para garantizar determinismo y salidas estructuradas estrictas) y **Max Tokens: 400** (para acotar la respuesta JSON del Structured Output Parser).

Métrica de Ejecución	Estimación por Ticket / Correo	Costo Real Actual (Groq)	Costo API Directa (OpenAI/Anthropic)
Tokens de Entrada (Prompt + Correo)	~800 tokens (incluye system prompt y cuerpo del correo naviero)	\$0.00 USD (Tier Gratuito / Promocional de Groq)	~\$0.00012 USD (gpt-4o-mini) / ~\$0.003 USD (Claude Sonnet)
Tokens de Salida (JSON Estructurado)	~150 tokens (delimitados por max_tokens=400)		~\$0.00009 USD (gpt-4o-mini) / ~\$0.0015 USD (Claude Sonnet)
Costo Total por 1,000 Ejecuciones	~950,000 tokens totales combinados	\$0.00 USD	~\$0.21 USD (gpt-4o-mini) a ~\$4.50 USD (Claude)

4. Escalabilidad Masiva y Uso de la API de Batches

Aunque el volumen actual es bajo (entorno académico), si el flujo se desplegara en una operación real con un volumen masivo de **100,000 correos mensuales**, la estrategia de optimización evolucionaría incorporando la **API de Lotes (Batches)**:

- **Descuento del 50% en Inferencia:** Proveedores como OpenAI ofrecen la modalidad Batch procesando las solicitudes en un plazo de 24 horas con una reducción directa del costo de API de hasta un 50%.
- **Desacoplamiento Asíncrono en n8n:** En lugar de procesar cada correo en tiempo real mediante Webhook síncrono, se agruparían los payloads diarios en un archivo JSONL, se enviarían a la Batch API, y un nodo cron consultaría el estado para registrar masivamente en Airtable.

Justificación del Ahorro Presupuestario: La combinación de utilizar **Groq** en etapa de desarrollo/volumen bajo (ahorro del 100% frente a APIs comerciales) y la adopción teórica de **Batches API** para cargas masivas garantiza un **ahorro superior al 50% del presupuesto operativo** frente a llamadas síncronas estándar de alta gama.

5. Conclusión de la Matriz

La arquitectura diseñada demuestra dominio técnico de la gestión de modelos en n8n: se asignó un modelo principal robusto (gpt-oss-120b) para la lectura densa de cifras navieras, un fallback ágil (gpt-oss-20b) para la resiliencia ante errores, y se justificó el modelo financiero mediante métricas de tokens y estrategias de procesamiento por lotes.